



Глубокое обучение для обработки изображений

Лекция 8

Детекция и сегментация



Примеры задач детекции объектов (слева)
и семантической сегментации (справа)

Детекция объектов (Object Detection)



Самый простой способ: рассматривать
небольшие части изображения и для
каждого из них делать предсказание, есть
ли объект или нет

Детекция объектов (Object Detection)



Самый простой способ: рассматривать
небольшие части изображения и для
каждого из них делать предсказание, есть
ли объект или нет


Детекция объектов (Object Detection)



Самый простой способ: рассматривать небольшие части изображения и для каждого из них делать предсказание, есть ли объект или нет


Объекты могут быть разного размера, их может быть много и т.д., поэтому нам потребуется использовать тысячи таких областей разного масштаба

Region proposal




Идея состоит в том, чтобы с помощью, например, алгоритма Selective Search найти области на картинке, которые могут содержать объекты. Это позволит не перебирать множество различных областей простым перебором.

Region proposal




[A class-independent flexible algorithm to generate region proposals](#)


R-CNN (Region-based CNN)




R-CNN (Region-based CNN)



R-CNN (Region-based CNN)




R-CNN (Region-based CNN)



1. Input image



2. Extract region proposals (~2k)



3. Compute CNN features

4. Classify regions

5. Bounding Box Regressor
[x, y, w, h]

Комбинированная функция потерь:
предсказание класса (cross-entropy loss) +
SVM классификатор (Hinge loss) +
предсказание координат бокса (MSE)

Предсказывает 4 числа – уточняют
расположение бокса внутри
области, предсказанной на region
proposal stage

Время предсказания ~ 1 минута на картинку

Fast R-CNN




Figure 1. Fast R-CNN architecture. An input image and multiple regions of interest (ROIs) are input into a fully convolutional network. Each ROI is pooled into a fixed-size feature map and then mapped to a feature vector by fully connected layers (FCs). The network has two output vectors per ROI: softmax probabilities and per-class bounding-box regression offsets. The architecture is trained end-to-end with a multi-task loss.

Fast R-CNN






Figure 1. Fast R-CNN architecture. An input image and multiple regions of interest (RoIs) are input into a fully convolutional network. Each RoI is pooled into a fixed-size feature map and then mapped to a feature vector by fully connected layers (FCs). The network has two output vectors per RoI: softmax probabilities and per-class bounding-box regression offsets. The architecture is trained end-to-end with a multi-task loss.


Время предсказания ~ 2-3 секунды на картинку. Теперь поиск регионов занимает большую часть времени.

Faster R-CNN




Теперь region proposals предсказываются с помощью Region Proposal Network

Faster R-CNN




Теперь region proposals предсказываются с помощью Region Proposal Network



Время предсказания ~ 0.2 секунды на картинку.

YOLO (You Only Look Ones)

[You Only Look Once: Unified, Real-Time Object Detection](#)



Осуществляем детекцию без
region proposals






Figure 2: The Model. Our system models detection as a regression problem. It divides the image into an $S \times S$ grid and for each grid cell predicts B bounding boxes, confidence for those boxes, and C class probabilities. These predictions are encoded as an $S \times S \times (B * 5 + C)$ tensor.

Non-maximum suppression

IoU – Intersection over Union

$$IoU = \frac{\text{Площадь пересечения}}{\text{Площадь объединения}} = \frac{A \cap B}{A \cup B}$$



Non-maximum suppression алгоритм:

Пусть S – массив, элементы которого содержат информацию о каждом боксе ($x_1, y_1, x_2, y_2, confidence$)

1. Выбрать бокс с наибольшим *confidence* и удалить его из S.
2. Найти IoU выбранного бокса со всеми остальными.
3. Удалить боксы с IoU большим порогового значения (часто берут 0.5) из S.
4. Повторять 1-3, пока в S есть боксы

One-stage и two-stage детекторы

Детекторы можно разделить на две большие группы:

- **Двухстадийные детекторы (two-stage detectors)**

На первом этапе находят region proposals, которые используются для нахождения объекта на втором этапе.

Выше качество, Больше время предсказания

Примеры: семейство R-CNN


- **Одностадийные детекторы (one-stage detectors)**

Этап region proposals отсутствует.

Ниже качество, меньше время предсказания

Примеры: семейство YOLO, SSD, RetinaNet, EfficientDet


Семантическая сегментация (Semantic Segmentation)



Можем использовать стандартную архитектуру из раздела классификации изображений, только без полно связного слоя в конце.

Слишком “резкий” upsampling до исходного размера картинки – границы областей получаются не четкими.

Семантическая сегментация (Semantic Segmentation)



Лучшие результаты показывает так называемая Hourglass (песочные часы) архитектура

Как можно делать upsampling?

| | |
|----|---|
| 2 | 1 |
| -2 | 4 |

Ближайших соседей
(Nearest Neighbor)

| | | | |
|----|----|---|---|
| 2 | 2 | 1 | 1 |
| 2 | 2 | 1 | 1 |
| -2 | -2 | 4 | 4 |
| -2 | -2 | 4 | 4 |

Input: 2x2

Output : 4x4

| | |
|----|---|
| 2 | 1 |
| -2 | 4 |

“Bed of Nails”

| | | | |
|----|---|---|---|
| 2 | 0 | 1 | 0 |
| 0 | 0 | 0 | 0 |
| -2 | 0 | 4 | 0 |
| 0 | 0 | 0 | 0 |

Input: 2x2

Output : 4x4

Как можно делать upsampling: Max Unpooling

Индексы максимальных значений
после **Max Pooling** сохраняются и
используются при **Max Unpooling**

| | | | |
|---|----|---|----|
| 2 | -4 | 2 | 1 |
| 0 | 1 | 0 | -1 |
| 2 | 1 | 4 | 2 |
| 5 | -3 | 1 | 0 |

Max pool, 2x2 filter


| | |
|---|---|
| 2 | 2 |
| 5 | 4 |




| | |
|---|----|
| 3 | -2 |
| 4 | 1 |

Max Unpooling


| | | | |
|---|---|----|---|
| 3 | 0 | -2 | 0 |
| 0 | 0 | 0 | 0 |
| 0 | 0 | 1 | 0 |
| 4 | 0 | 0 | 0 |



Как можно делать upsampling: Transposed convolution




U-net




Сегментация объектов (Instance Segmentation)




Image Recognition



Semantic Segmentation




Object Detection




Instance Segmentation

Сегментация объектов (Instance Segmentation)


1 stage instance segmentation



2 stages instance segmentation




Сегментация объектов (Instance Segmentation)



Метрики в сегментации и детекции

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$


← Если работаем с **боксами**
Если работаем с **сегм. масками** →



$$IoU = Jaccard\ Coefficient = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$


$$Dice = 2 \frac{|A \cap B|}{|A| + |B|}$$

$$Dice\ Coefficient = 2 \frac{|A \cap B|}{|A| + |B|}$$



Метрики в сегментации и детекции


$$IoU = \frac{|A \cap B|}{|A \cup B|}$$




← Если работаем с **боксами**

Если работаем с **сегм. масками** →

$$IoU = Jaccard\ Coefficient = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$



$$Dice = 2 \frac{|A \cap B|}{|A| + |B|}$$



$$Dice\ Coefficient = 2 \frac{|A \cap B|}{|A| + |B|}$$

В задаче **semantic segmentation** IoU вычисляется для каждого класса, а затем находится среднее значение — mean IoU (**mIoU** метрика)

Метрики в сегментации и детекции: mean Average Precision (mAP)

mAP показывает, насколько модель хорошо локализует объекты на изображении и правильно предсказывает классы (подробнее на практике)

Используется, например, в **object detection, instance segmentation**